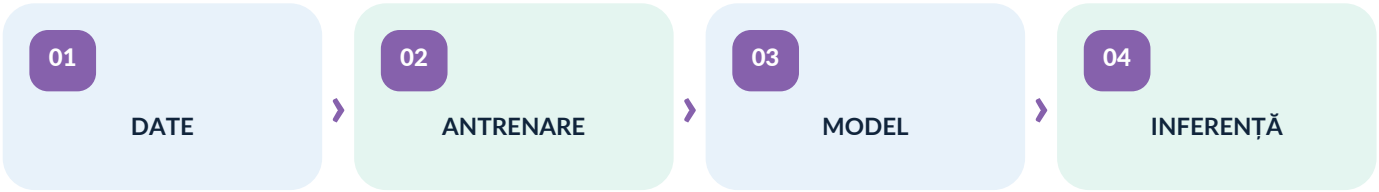
AI (Artificial Intelligence - inteligență artificială) · KV (Key-Value)

CUM FUNCȚIONEAZĂ CLUSTERELE AI

SCAN / LEARN

Antrenarea schimbă parametrii modelului; inferența produce răspunsuri.

SISTEMUL DINTR-O PRIVIRE



PATRU IDEI IMPORTANTE

1 ANTRENARE

Prelucrează repetat exemple și modifică parametrii modelului. Poate folosi multe procesoare grafice.

2 CHECKPOINT (PUNCT DE SALVARE)

Stare de antrenare salvată pentru reluare după întreruperi; ocupă timp și spațiu.

3 INFERENȚĂ

Modelul deja antrenat prelucrează cereri noi. Serviciul gestionează cereri și resurse.

4 KV CACHE (KEY-VALUE CACHE)

În inferența unor modele transformer, date de atenție intermediare memorate evită recalcularea tokenurilor vechi.

DE ȚINUT MINTE

Antrenarea construiește rețeta. Inferența o folosește. Ambele au nevoie de centre de date.

DISCUTAȚI FĂRĂ CALCULATOARE

Dacă modelul este antrenat, de ce poate răspunde totuși lent?

© 2026 VLAD BELCIUG • FREE FOR PERSONAL STUDY