De ce costă diferit răspunsurile AI

Tokenuri, calcul, așteptare și reutilizare

SCAN / LEARN

09 / 12 • GHID VIZUAL

IDEEA CENTRALĂ

Costurile AI depind de munca efectuată, nu doar de numărul întrebărilor. Alegerea potrivită evită calculul inutil.

URMĂREȘTE SISTEMUL

01

MĂRIMEA CERERII

Mai multe tokenuri de intrare cer procesare.

02

ALEGEREA MODELULUI

Modelele diferă ca viteză și cost.

03

RĂSPUNS ȘI TIMP

Generarea mai lungă consumă timp și calcul.

04

REUTILIZARE

Cache-ul sigur poate evita calcule repetate.

TOKENURI + MODEL + TIMP − REUTILIZARE = COST

CONFUZIE FRECVENTĂ

Cel mai ieftin sau rapid răspuns este automat cel mai bun.

MAI CORECT

Calitatea, corectitudinea, confidențialitatea și întârzierea contează.

TREI ÎNTREBĂRI DE REȚINUT

PROBLEMA: Cum consumăm inteligent resursele?

DACĂ EȘUEAZĂ: Risipa și așteptarea pot bloca serviciul.

ÎN REALITATE: Conversații, agenți, căutare, suport.

EXPLORARE INDIVIDUALĂ

Încearcă singur: compară efortul unui „Salut!” cu rezumarea unui raport lung.